

Proyecto Estadístico

MAT306

Profesor: Francisco Alfaro

Estudiantes: Vicente Moreno, Joaquín Ramírez, Nicolás Rodríguez, Yunis Vidal.
Universidad Técnica Federico Santa María



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA
Departamento de Matemática

1 Problema

2 Datos/EDA

3 Método/Validación

4 Interpretabilidad

5 Limitaciones

6 Conclusiones

Uno de los desafíos que enfrentan las grandes tiendas, como Walmart, es la capacidad de determinar de manera inequívoca la demanda de sus productos.



A medida que la cantidad de consumo crece, los patrones de este mismo se vuelven dinámicos y difíciles de predecir. La necesidad de contar con modelos robustos de forecasting se vuelve fundamental para las gestiones operativas.

1 Problema

2 Datos/EDA

3 Método/Validación

4 Interpretabilidad

5 Limitaciones

6 Conclusiones

Tenemos 5 archivos :

- calendar : Días del calendario, feriados, días de cupones por estado.
- sales_train_evaluation : Productos y la tienda donde provienen, cantidad de ventas durante el periodo medido.
- sales_train_validation : Igual que sales_train_evaluation, utilizado para validar los modelos.
- sample_submission : Utilizado para Kaggle.
- sell_prices : Precio de cada producto por día durante el periodo.

Hagamos un análisis exploratorio breve...

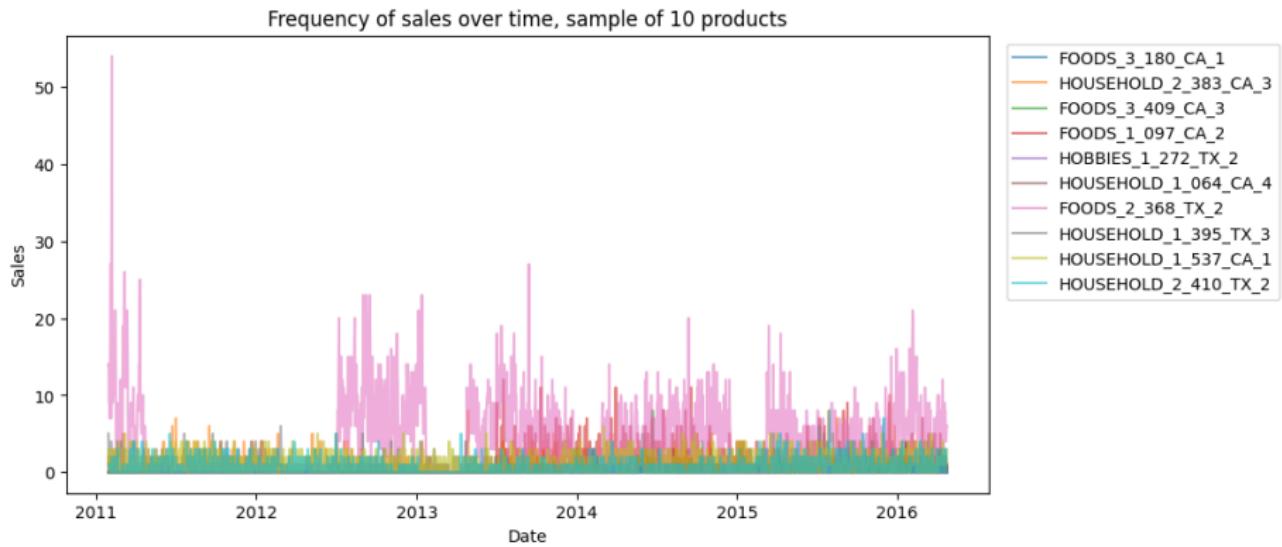


Figure – Cantidad de ventas diarias para una muestra de 10 productos.

Frequency of total sales per day, over time

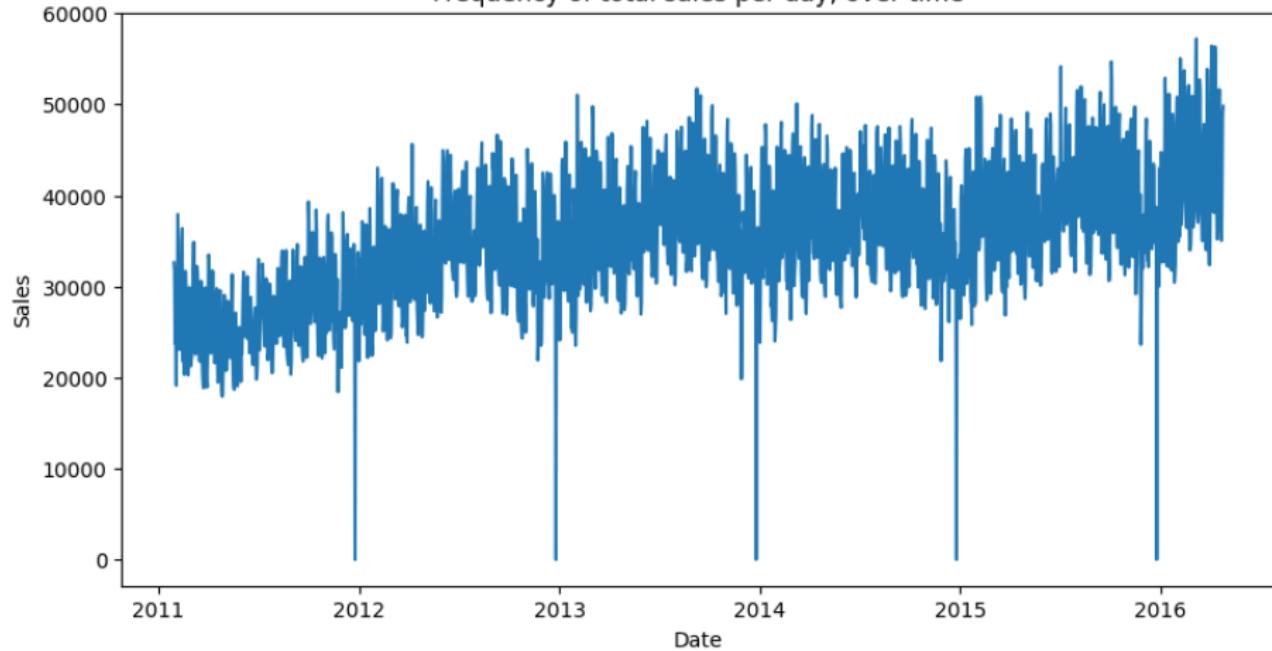


Figure – Cantidad de ventas diarias totales.

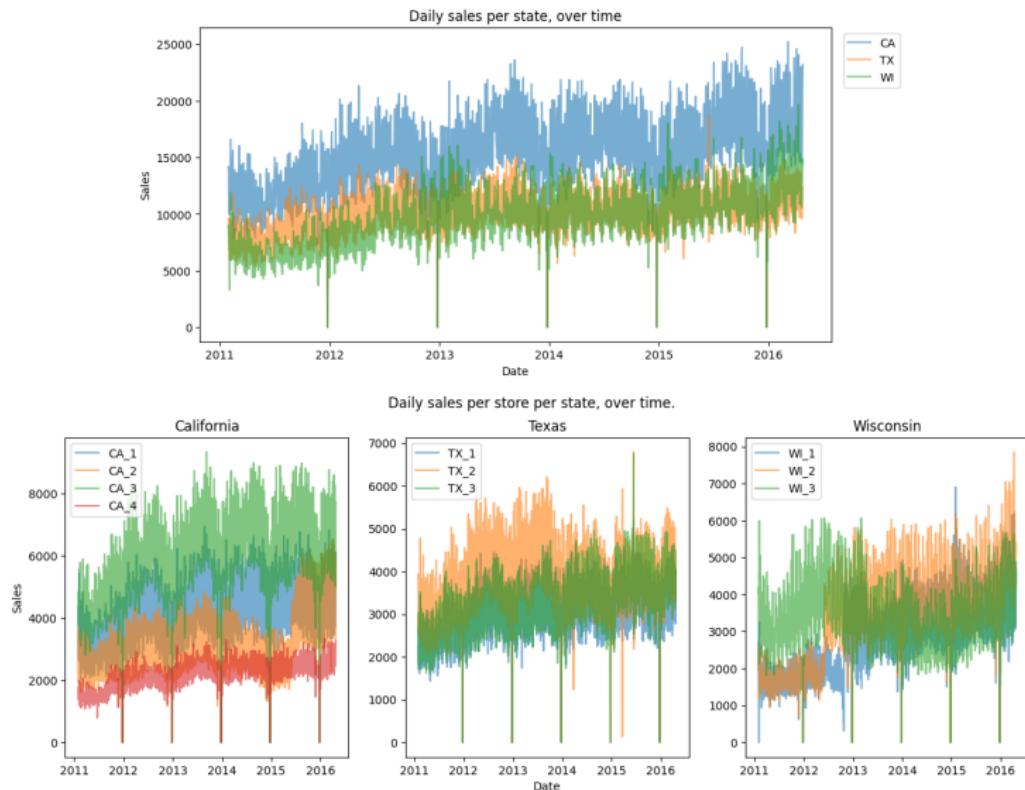


Figure – Cantidad de ventas diarias totales, separadas por estado y por tienda.

Daily sales per department per state, per time.

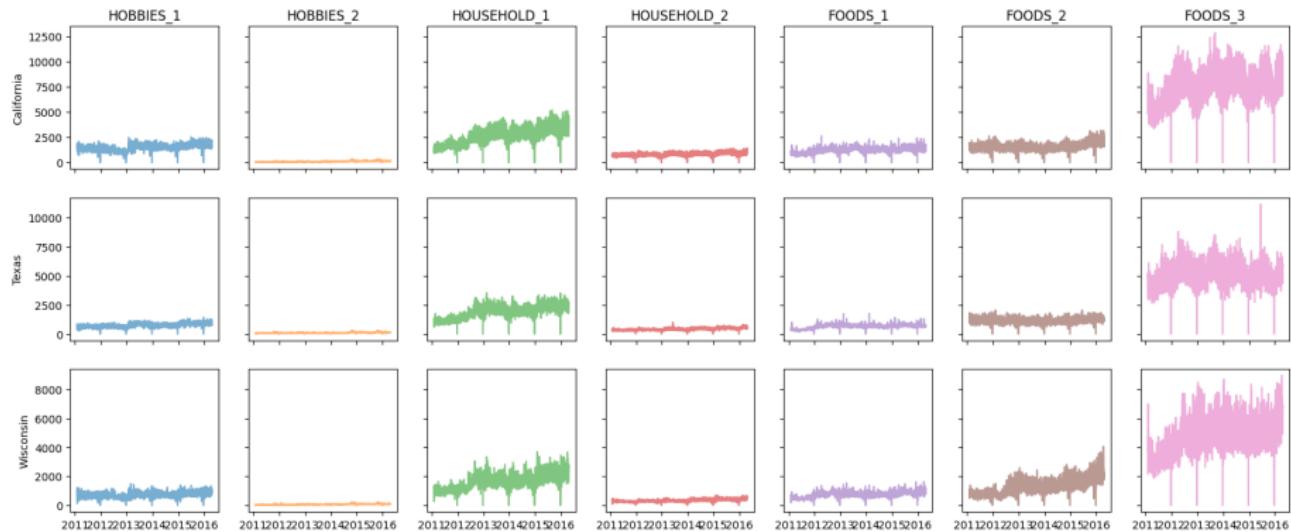


Figure – Cantidad de ventas diarias totales, separadas por departamento.

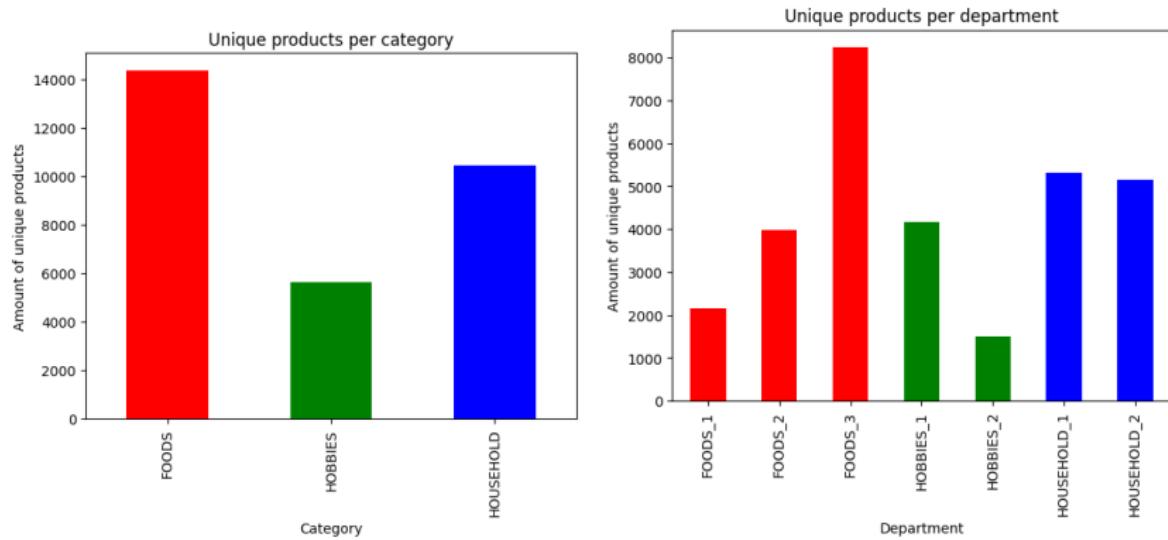
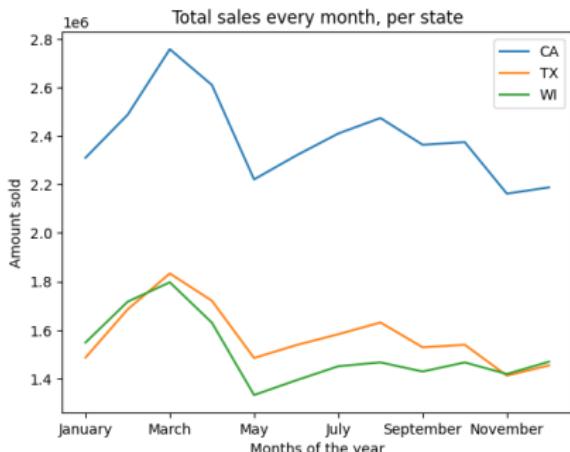
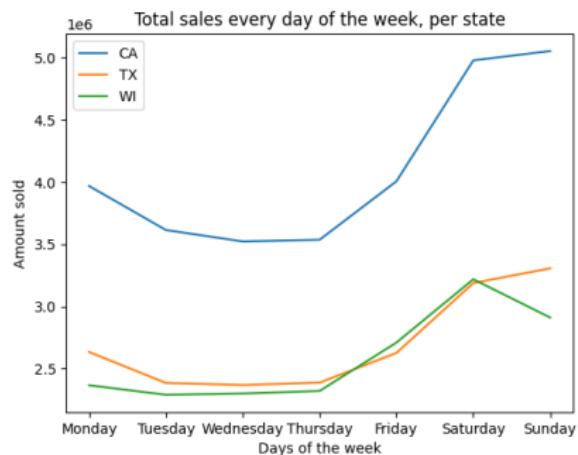


Figure – Cantidad de productos distintos por departamento y por tipo.



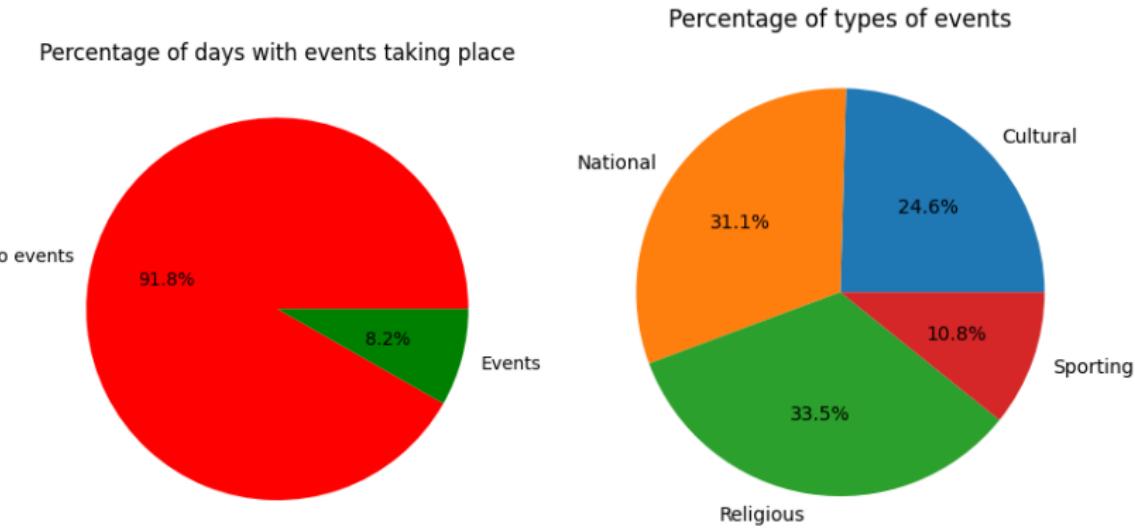


Figure – Proporción de días que hubo eventos, y de que tipo.

Total sales every day of the month per state, SNAP days highlighted

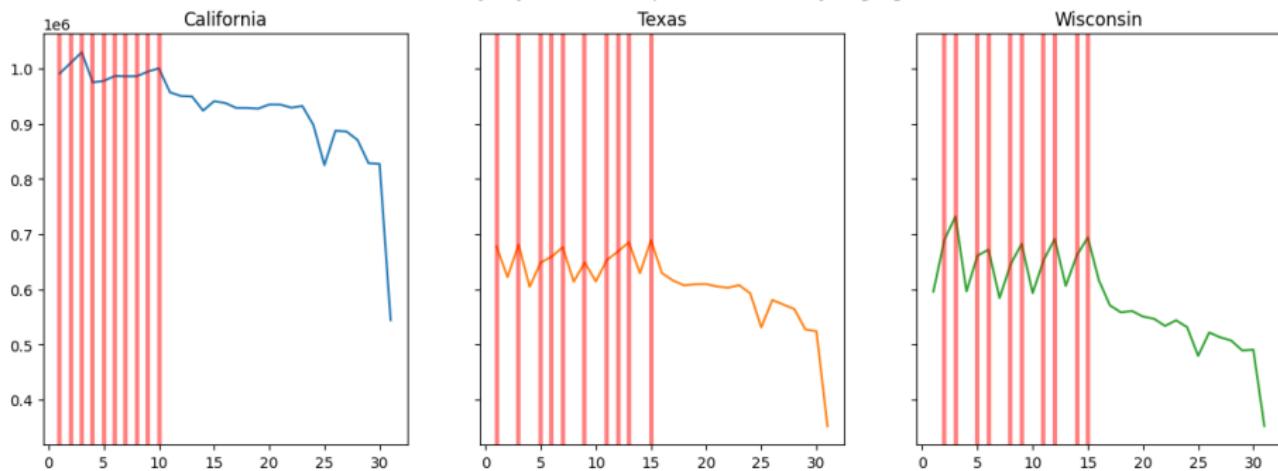


Figure – Volumen de ventas por día del mes por estado. Están marcado en rojo los días que los cupones SNAP están disponibles.

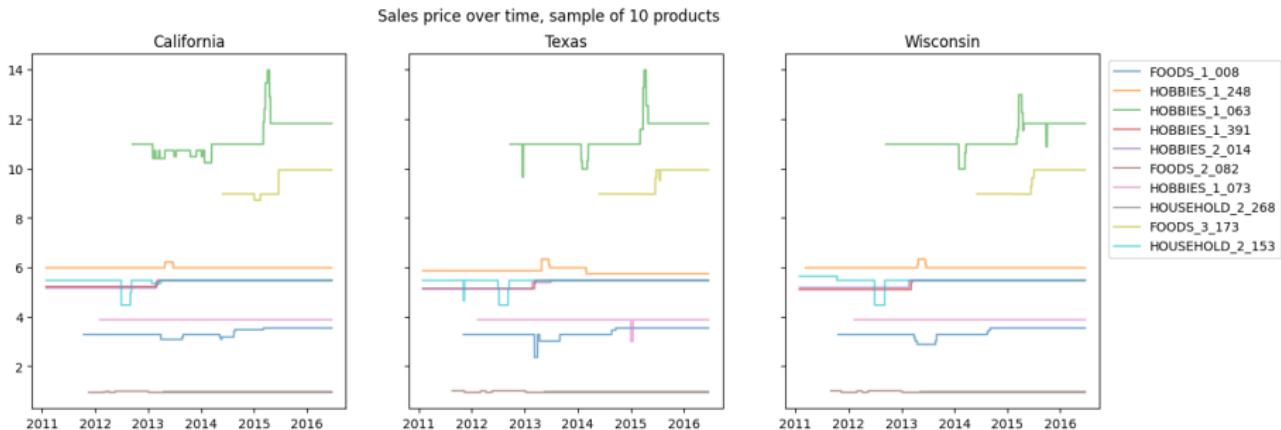


Figure – Precio de 10 productos a lo largo del tiempo, en cada estado.

En virtud de lo anterior, se agregan las siguientes nuevas features.

- Precio/Venta lag de un dia y una semana.
- Precia/Venta window de un dia y una semana.
- Feature indicadora de eventos

- 1 Problema
- 2 Datos/EDA
- 3 Método/Validación
- 4 Interpretabilidad
- 5 Limitaciones
- 6 Conclusiones

Método

Se utilizó el ultimo año. Los modelos que ocupamos :

- Snaive con estacionalidad mensual por tienda.
- SARIMA por estado.
- XGBoost con features nuevas.
- Red neuronal con features nuevas.

Validación/Resultados

Se decantó utilizar SARIMA por estado debido a el pobre rendimiento de XGBoost y una RNN

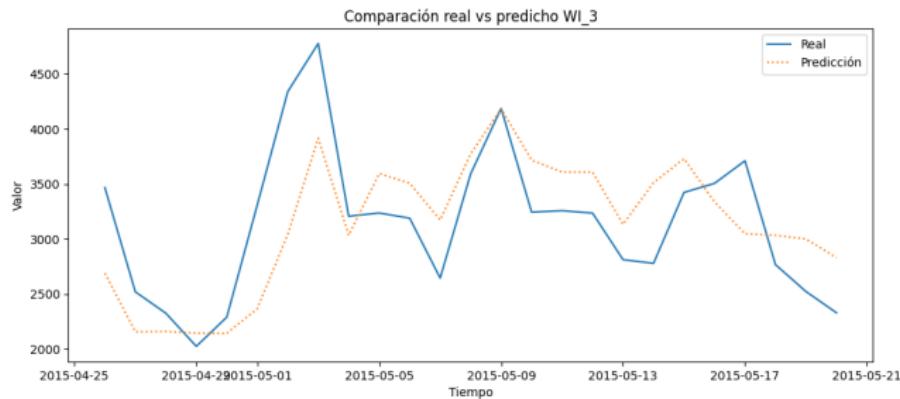


Figure – Predicción RNN V/S Real, Ventas, Texas.

Validación/Resultado

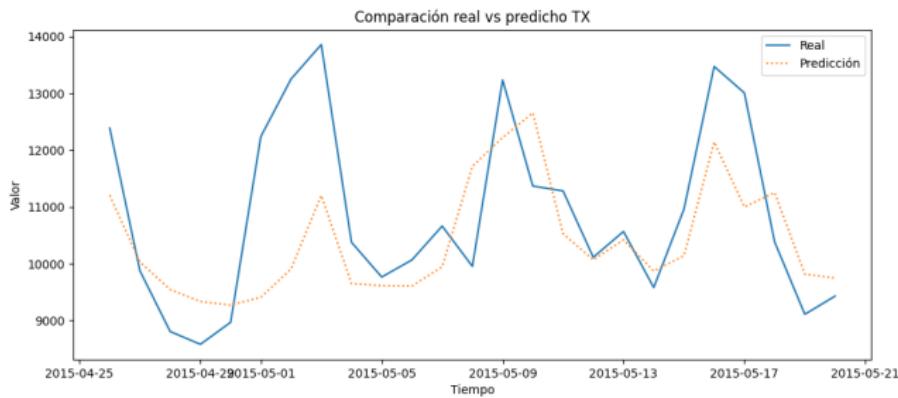


Figure – Predicción XGBoost V/S Real, Ventas, Texas.

Validación/Resultado

Métricas promedios resultantes de XGBoost

	CA_1	CA_2	CA_3	CA_4	TX_1	TX_2	TX_3	WI_1	WI_2	WI_3
RMSE	665.890381	517.884247	752.896822	251.819954	387.622924	454.659213	637.299209	519.750361	738.859890	638.858014
MAE	516.986511	433.749756	552.084900	202.770660	275.069153	348.885071	506.264526	436.970459	580.237549	397.711884
R2	-0.073585	-2.924473	-0.785610	-0.901786	-0.325785	-0.229720	-2.776066	-0.618028	-0.799429	-1.751694

Figure – Metricas por Estado.

Es mejor llenar con media...

Validación/Resultado

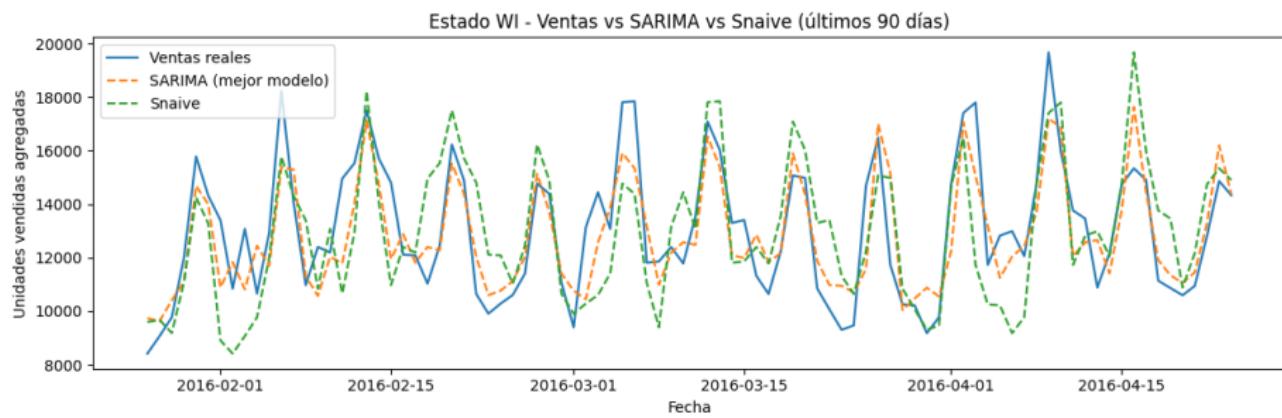


Figure – Arima V/S Naive V/S Real, Ventas, Texas.

- 1 Problema
- 2 Datos/EDA
- 3 Método/Validación
- 4 Interpretabilidad
- 5 Limitaciones
- 6 Conclusiones

Los mejores modelos utilizarán una feature, lo que hace que la interpretabilidad no haga sentido para estos modelos.

Por otro lado, los modelos que utilizan todas las features, se desempeñaron mucho peor. No vale la pena hacer el análisis.



- 1 Problema
- 2 Datos/EDA
- 3 Método/Validación
- 4 Interpretabilidad
- 5 Limitaciones
- 6 Conclusiones

Limitaciones

1. Datos altamente heterogéneos

- Miles de series con distintos niveles, miles de productos, diferentes tiendas.
- Diferentes escalas y patrones dificultan la optimalidad de un solo modelo.

2. Horizonte de predicción fijo

- Los errores amplifican en series intermitentes y/o ruidosas.
- Pronosticar para productos con baja demanda es muy inestable.

3. Complejidad computacional

- 42.000 series jerárquicas implican un alto costo de entrenamiento y tuning.
- Integrar efectos calendario, estacionalidad múltiple y covariables aumenta la carga.

- 1 Problema
- 2 Datos/EDA
- 3 Método/Validación
- 4 Interpretabilidad
- 5 Limitaciones
- 6 Conclusiones

Estado WI - Ventas vs SARIMA vs Snaive (últimos 90 días)

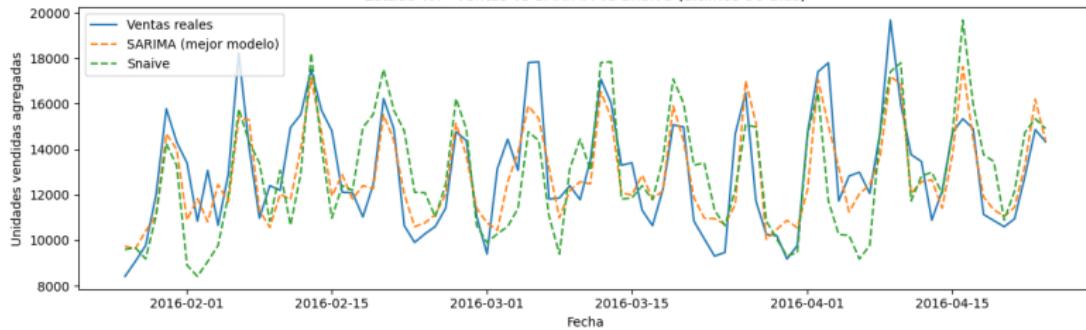


Figure – Arima V/S Naive V/S Real, Ventas Texas

Métrica	Valor
RMSSE_mean	0.615363
RMSSE_std	0.230157
RMSE_mean	1182.497442
RMSE_std	442.275807
MAE_mean	969.423765
MAE_std	357.065238

Table – Modelos Aplicado en Texas.

Próximos pasos

Próximo paso propuesto	Beneficio que habilita
Ingeniería de nuevas features (estacionalidad fina, precios, promociones, clima)	Incremento en la precisión del pronóstico a nivel SKU/tienda.
Validación temporal más robusta (rolling origin, evaluación jerárquica)	Reducción de quiebres de stock y sobrestock al obtener pronósticos más confiables.
Optimización del pipeline y actualización periódica del modelo	Mejor planificación logística y abastecimiento ; decisiones más oportunas.